

GRLA: Bridging Softmax and Linear Attention via Gaussian RBF Kernel for lightweight image Super-Resolution

Introduction

La **super-résolution d'images** vise à reconstruire une image haute résolution **HR** à partir d'une image basse résolution **LR**. Elle requiert la modélisation des dépendances spatiales pour restaurer les textures et les structures fines.

Défi. Les mécanismes d'attention à base de la fonction **Softmax** permettent de modéliser ces interactions globales, au prix d'une complexité $O(n^2)$ peu adaptée aux modèles dits *lightweight*.

Solution. Le papier introduit **MPB**, une architecture de super-résolution légère reposant sur une **attention linéaire basée sur un noyau Gaussien (GRLA)**. Cette formulation conserve une **sensibilité à la distance** entre représentations, tout en maintenant une complexité linéaire.

Données

Entraînement.

DIV2K : 800 images en haute résolution (2K)
Génération des images **LR** par **sous-échantillonnage bicubique** ($\times 4$)
Patches aléatoires 64×64 (LR)
Augmentation : rotations, flips H/V
Entraînement sur le **canal Y (YCbCr)**

Validation.

Benchmark avec des jeux de test: **Set5**, **Set14** et **BSD100**
Comparaison avec une **baseline bicubique**
Suppression des pixels de bord pour éviter les artefacts d'upsampling

Dépôt GitHub:

<https://github.com/redscarfx/GRLA>.

RBF Radial Basis Function

GRLA/GRBFLA Gaussian RBF Linear Attention

SR Super-Resolved image

HR High-Resolution image

LR Low-Resolution image

PSNR Peak Signal-to-Noise Ratio

SSIM Structural Similarity Index Measure

Méthode et modèle GRLA

GRLA reformule l'attention Softmax comme un **noyau Gaussien RBF dépendant de la distance**:

$$K(Q_i, K_j) = \exp(-\gamma \|Q_i - K_j\|^2) = \exp(-\gamma \|Q_i\|^2) \exp(-\gamma \|K_j\|^2) \exp(2\gamma Q_i^\top K_j).$$

À l'aide d'un **développement de Taylor d'ordre 1**: $\exp(2\gamma Q_i^\top K_j) \approx 1 + 2\gamma Q_i^\top K_j$.

$$K(Q_i, K_j) \approx \phi(Q_i) \phi(K_j) (1 + 2\gamma Q_i^\top K_j), \quad \phi(X) = \exp(-\gamma \|X\|^2).$$

$$\alpha_i = \frac{\sum_{j=1}^N \phi(Q_i) \phi(K_j) (1 + 2\gamma Q_i^\top K_j) V_j}{\sum_{j=1}^N \phi(Q_i) \phi(K_j) (1 + 2\gamma Q_i^\top K_j)} = \frac{\sum_j \phi(K_j) V_j + 2\gamma Q_i^\top \sum_j \phi(K_j) K_j V_j}{\sum_j \phi(K_j) + 2\gamma Q_i^\top \sum_j \phi(K_j) K_j} \sim O(n)$$




Figure: Architecture du modèle à base de GRLA de 7 blocs de $\langle TWSA + TLA \rangle$.

Les performances sont évaluées à l'aide de métriques standards en super-résolution. Pour une vérité terrain **HR** et une reconstruction **SR** de la même résolution:

$$\text{PSNR}(\text{HR}, \text{SR}) = -10 \cdot \log_{10} \left(\frac{\text{MSE}(\text{HR}, \text{SR})}{\text{MAX}^2} \right)$$

$$\text{SSIM}(\text{HR}, \text{SR}) = \frac{(2\mu_{\text{HR}}\mu_{\text{SR}} + (k_1L)^2)(2\sigma_{\text{HR,SR}} + (k_2L)^2)}{(\mu_{\text{HR}}^2 + \mu_{\text{SR}}^2 + (k_1L)^2)(\sigma_{\text{HR}}^2 + \sigma_{\text{SR}}^2 + (k_2L)^2)} \quad \text{avec } k_1 = 0.01, \quad k_2 = 0.03.$$

PSNR (dB) élevé indique une **faible erreur pixel-à-pixel** entre les deux images **SR** et **HR**. Cette métrique, exprimée sur une **échelle logarithmique non bornée**, mesure principalement *la ressemblance numérique*. **MAX** est le pixel à valeur maximale dans les deux images. $\text{MAX} = 1$ après la normalisation des données.

SSIM proche de 1 traduit une **forte similarité structurelle perceptuelle**. Bornée dans $[0, 1]$, cette métrique est mieux corrélée à la qualité visuelle ressentie en évaluant la cohérence des structures locales. L représente la gamme dynamique. $L = 1$ après la normalisation des données.

Résultats

Le modèle de **MPB** avec 7 blocs a été entraîné pendant **170 epochs** avec **Adam** et une perte **L1 (MAE)**.




Figure: Exemples d'un batch avec 4 images en version LR, HR et SR prédite par le modèle.

		Bicubic (baseline)	GRLA (orig.)	GRLA (ours)
	Params(K)	—	885	863
Set5	PSNR (dB)	27.66	32.64	<u>29.30</u>
	SSIM (%)	81.32	90.01	<u>86.52</u>
Set14	PSNR (dB)	24.54	28.89	<u>25.54</u>
	SSIM (%)	68.99	78.80	<u>72.96</u>
BSD100	PSNR (dB)	25.24	27.78	<u>25.93</u>
	SSIM (%)	64.64	74.37	<u>66.20</u>

Table: Comparaison des performances en super-résolution $\times 4$ entre l'interpolation bicubique, le modèle GRLA original et notre implémentation. Le meilleur score est en **gras**, le second meilleur score est souligné. La baseline Bicubic ne nécessite aucun paramètre à entraîner.

Conclusion

L'entraînement limité à **170 epochs** (vs. 1000 dans le papier) restreint la comparabilité des deux. Le papier manque de détails sur les hyperparamètres, l'implémentation et le prétraitement, ce qui limite la reproductibilité et l'évaluation des gains.